



SH320 Data Engineering

Spring 2026 Semester

8 Handling Missing Data

Hyun Ahn

School of Computing and Artificial Intelligence

hyunahn@hs.ac.kr

Core Libraries for Data Science



- **[W2] N-Dimensional Arrays**
 - NumPy arrays
 - Array manipulation
- **[W3] Efficient Computation in NumPy**
 - Universal functions
 - Advanced features

- **[W5] Data Manipulation: Part 1**
 - Pandas objects: Series, DataFrame
 - Implicit / explicit indexing
- **[W6] Data Manipulation: Part 2**
 - Pandas objects & manipulation
 - Combining datasets
 - Exploratory data analysis

Data Engineering



- **[W7] Data Acquisition**
 - Web scraping
 - RESTful API

- **[W9] Working with Time Series**
 - Time series manipulation
 - Time-series-specific operations

- **[W10] Handling Missing Data**
 - Missing data problems
 - Processing missing data in Python

8.1 결측 데이터 문제

DW&DC Main Goal: High Data Quality!



데이터 품질 평가를 위한 기준


- **완전성** completeness
필수항목에 누락이 없어야 한다.
- **유효성** validity
데이터 항목은 정해진 데이터 유효범위 및 도메인을 충족해야 한다.
- **정확성** accuracy
데이터 항목의 값은 실세계에 존재하는 객체를 정확히 반영해야 한다.
- **유일성** uniqueness
데이터 항목은 유일해야 한다.
- **일관성** consistency
데이터의 구조, 값, 표현 형태가 일관되게 정의되고 서로 일치해야 한다.

품질 기준	세부 품질기준	품질기준 설명	활용 예시
완전성	개별 완전성	필수 컬럼에는 값의 누락이 없어야 한다.	고객의 아이디는 NULL일 수 없다.
	조건 완전성	조건에 따라 컬럼 값이 항상 존재해야 한다.	기업 고객의 사업자 등록번호가 NULL일 수 없다.
유효성	범위 유효성	컬럼 값이 주어진 범위내에 존재해야 한다.	기준점 좌표각은 -360 초과 360미만까지의 값을 가진다.
	날짜 유효성	컬럼 값이 날짜유형일 경우에는 유효날짜 값을 가져야 한다.	99991231, 20080231은 유효하지 않은 값이다.
	형식 유효성	컬럼은 정해진 형식과 일치하는 값을 가져야 한다.	주민번호형식은 '999999-99999999'의 형식이어야 한다.
정확성	선후관계 정확성	복수의 컬럼값이 선후 관계에 있을 경우 이 규칙을 지켜야 한다.	시작일은 종료일 이전 시점이어야 한다.
	계산/집계 정확성	한 컬럼의 값은 다수 컬럼의 계산된 값일 경우 계산 값이 정확해야 한다.	월 통계 테이블의 매출액은 기산일이 현월인 매출액의 총합과 일치해야 한다.
	최신성	정보의 발생, 수집, 그리고 갱신 주기를 유지해야 한다.	고객의 현재 값은 고객변경이력의 마지막 ROW와 일치해야 한다.
	업무규칙 정확성	컬럼이 업무적으로 복잡하게 연관된 경우 관련 업무규칙에 일치해야 한다.	지급원장의 지급여부가 'Y'이면 지급원장의 지급일자 는 신청일보다 이전시점 이어야 하고 NULL이 아니어야 한다.
유일성	단독 유일성	컬럼은 유일한 값을 가져야 한다.	고객의 이메일 주소는 유일해야 한다.
	조건 유일성	업무 조건에 따라 컬럼 값은 유일해야 한다.	교육과정의 강의시작일이 있으면, 강의실 코드, 임대일, 강사코드가 모두 동일한 레코드는 존재하지 않는다.
일관성	기준코드 일관성	컬럼이 통합코드를 기준코드로 사용할 경우 그 참조무결성을 유지해야 한다.	고객의 직업코드는 통합코드테이블의 직업코드에 등록된 값이어야 한다.
	참조무결성	테이블간의 컬럼값이 참조관계에 있는 경우 그 무결성을 유지해야 한다.	대출원장의 대출원장번호는 대출 상세내역에 존재해야 한다.
	데이터 흐름 일관성	데이터를 생성하거나 가공하여 데이터가 이동되는 경우, 연관된 데이터는 모두 일치해야 한다.	운영계의 현재 가입 고객 수와 DW의 고객 수는 일치해야 한다.
	컬럼 일관성	관리 목적으로 중복 컬럼을 임의 생성하여 활용하는 경우 각각의 동의어 컬럼 값은 일치해야 한다.	주문의 주문번호와 고객번호는 배송의 주문번호와 고객번호가 서로 일치해야 한다.

MISSING DATA

MISSING DATA EVERYWHERE!

memegenerator.net



DD 유형 1: 빠져 있는지 우리가 아는 데이터

DD 유형 2: 빠져 있는지 우리가 모르는 데이터

DD 유형 3: 일부 사례만 선택하기

DD 유형 4: 자기 선택

DD 유형 5: 중요한 것이 빠짐

DD 유형 6: 존재했을 수도 있는 데이터

DD 유형 7: 시간에 따라 변하는 데이터

DD 유형 8: 데이터의 정의

DD 유형 9: 데이터의 요약

DD 유형 10: 측정 오차 및 불확실성

DD 유형 11: 피드백과 게이밍

DD 유형 12: 정보 비대칭

DD 유형 13: 의도적인 다크 데이터

DD 유형 14: 조작된 합성 데이터

DD 유형 15: 데이터 너머로 외삽하기

Dark Data #1: Data We Know Are Missing



- DD 유형 1: 빠져 있는지 우리가 아는 데이터
 - **Known unknowns:** 데이터에 무엇이 빠져 있는지는 알지만 그 값이 무엇인지는 모르는 경우
 - 예: 설문조사 미응답 항목
 - 예: 영국의 트라우마 환자 DB
 - 165,559건의 트라우마 사례 중 결과가 알려지지 않은 사례가 19,289건
 - 결과는 환자가 부상 후 30일 이후의 생존 여부를 나타냄
 - 빠져 있는 데이터의 비율은 작지만, 무시할 수 있는지?

Dark Data #2: Data We Don't Know Are Missing

- DD 유형 2: 빠져 있는지 우리가 모르는 데이터
 - **Unknown unknowns**: 데이터에 무엇이 빠져 있는지조차 모르는 경우

There are known knowns; there are things we know that we know.

There are known unknowns; that is to say, there are things that we now know we don't know.

But there are also unknown unknowns – there are things we do not know we don't know.

-Donald Rumsfeld



Dark Data #2: Data We Don't Know Are Missing



- DD 유형 2: 빠져 있는지 우리가 모르는 데이터
 - 예(보스턴시 포트홀 탐지 앱): 자동차/스마트폰 수의 지역적 불균형(부유한 지역 vs 가난한 지역) → 부유한 지역의 포트홀을 더 많이 탐지 및 보강공사 → 사회적 불평등 야기
 - 예(슈퍼태풍 샌디와 SNS): 태풍 피해 관련 트윗 메시지가 맨하튼에서 가장 많이 발생함 ≠ 피해가 가장 많이 발생한 지역? SNS 유저가 적은 지역은?

Dark Data #13: Intentionally Darkened Data




- DD 유형 13: 의도적인 다크 데이터
 - 예(암맹평가, 블라인드 테스트): 공정성을 목적으로 한 다크 데이터의 도입
 - 예(EU 젠더 지침이 보험비에 미친 영향): EU 젠더 지침에 의해 보험 회사에서 고객에게 청구할 보험비를 산정할 때 “성별”을 반영할 수 없음
 - 성별은 법에 의해 강제로 감춰지는 다크 데이터로 존재
 - 문제는 자동차 보험과 같이 실제 고객의 사고 위험성을 평가할 때 “성별” 변수는 설명력이 높으며 상관관계가 존재함에도 불구하고 이를 평가 모형에 포함할 수 없다는 점


Why We Need to Handle Missing Data?

- 결측치가 끼치는 영향


- 통계적 측면: 데이터의 통계적 특성을 왜곡, 표본 크기 감소
- 머신러닝 측면: 예측 모델 정확도 저하, 편향된 모델 학습(특정 패턴에 결측이 주로 발생하는 경우)



Why We Need to Handle Missing Data?




↓ imputing missing values



HANDLING MISSING DATA

By: Chanin Nantasenamat



결측 데이터 처리과정

1. 데이터의 결측치가 존재하는지?
2. 결측치가 있다면 어떤 유형인지?
3. 결측치 유형에 맞는 처리 방법은 무엇인지?

Missing Data Mechanisms



- 데이터 결측 메커니즘: 결측치 발생에 영향을 미치는 인과관계에 따라 분류
 - **MCAR** Missing Completely at Random, 완전 무작위 결측 🙄
 - **MAR** Missing at Random, 무작위 결측 🤖
 - **MNAR** Missing Not at Random, 비무작위 결측 🧐


- **MCAR:** Missing Completely at Random, 완전 무작위 결측
 - 결측치가 다른 변수들과 무관하게 발생한 경우
 - 예: 전산 오류, 기계의 오작동
 - 예: 설문조사에서 응답자가 실수로 일부 문항을 건너뛴 경우
 - 결측치와 관측치는 동일한 분포를 가진다고 가정
 - 가장 이상적인 경우지만, 현실에서 그럴 가능성이 높지 않음

Completely Observed Variable (**X**): 결측치가 없는 변수

Partly Missing Variable (**Y**): 일부 데이터가 결측된 변수

Missingness (**Z**): 데이터셋 외부에서 발생한 결측


Missingness (**R**): 데이터셋 내에서 발생한 결측



Mobile ID	Mobile Package	Download Speed	
1	Fast+	157	Missing because of data limit fully utilized
2	Lite	99	
3	Fast+	167	
4	Fast+	N/A	

It might be able to predict from other variable

- **MAR:** Missing at Random, 무작위 결측
 - 결측치의 발생이 오직 관측된 변수와 관계가 있음 (= 관측된 변수로 추정 가능)
 - 예: 여자들은 본인의 몸무게를 묻는 질문에 응답할 가능성이 남자보다 적다.
 - 예: 남자들은 우울증 설문조사에 응답할 가능성이 여자보다 적다.
 - 일반적으로 MCAR 보다 흔하게 발생




X Y R Z

Mobile ID	Mobile Package	Download Speed	Data Limit Usage	
1	Fast+	157	80%	When Data limit Usage reached 100%, missing has occurred , Missing depends on other observed variable
2	Lite	99	70%	
3	Fast+	167	10%	
4	Fast+	N/A	100%	

It might be able to predict using observed variables

- **MNAR:** Missing Not at Random, 비 무작위 결측
 - MCAR, MAR 유형이 아닌 경우
 - 결측치가 임의로 발생하는 것이 아닌 **관측된/관측되지 않은 변수와 관련**이 있음
 - 관측된 데이터로는 설명이 어려우므로, 데이터에 대한 추가 조사 필요



				X	Y	R	Z
Mobile ID	Mobile Package	Download Speed	Data Limit Usage				
1	Fast+	N/A	80%				
2	Lite	99	70%				
3	Fast+	167	10%				
4	Fast+	N/A	75%				

Download speed missing value has relation to Download Speed, Data Limit Usage and some other unknown variable. Here value is missing beyond a data limit usage range ($\geq 75\%$) but we can not predict the value

It is difficult to predict missing values

Methods for Handling Missing Data



- **제거**^{deletion}
 - Listwise deletion
 - Pairwise deletion
 - Variable deletion
- **단순 대치**^{simple imputation}
 - Mean/Median/Mode substitution
 - LOCF, NOCB
- **보간**^{interpolation}
 - Linear interpolation
 - Spline interpolation
- **모델 기반 대치**^{model-based imputation}
 - Regression
 - k-NN
 - EM
 - MICE
 - Machine learning/Deep learning approaches
- 수작업 with 도메인 지식

Discard Data



- **Listwise deletion:** 결측치를 포함하는 레코드(샘플)를 삭제
- **Pairwise deletion:** 해당 결측치만 삭제
- **Variable deletion:** 변수(컬럼) 자체를 삭제
 - 특정 변수의 결측 비율이 높은 경우

Listwise deletion

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	N/A	N/A	95%
8	Lite	76	77%
9	Fast+	180	N/A

← Delete

← Delete

← Delete



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
5	Lite	76	70%
6	Fast+	155	10%
8	Lite	76	77%

Pairwise deletion

Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	N/A	N/A	95%
8	Lite	76	77%
9	Fast+	180	N/A

← Delete

← Delete

← Delete



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+		80%
5	Lite	76	70%
6	Fast+	155	10%
7			95%
8	Lite	76	77%
9	Fast+	180	

Variable deletion

Delete



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	N/A	80%
2	Lite	N/A	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	N/A	10%
7	Fast+	N/A	95%
8	Lite	76	77%
9	Fast+	180	77%



Mobile ID	Mobile Package	Data Limit Usage
1	Fast+	80%
2	Lite	70%
3	Fast+	10%
4	Fast+	80%
5	Lite	70%
6	Fast+	10%
7	Fast+	95%
8	Lite	77%
9	Fast+	77%

Retain All Data: Simple Imputation



- **Mean substitution(평균대체)**
 - 평균값으로 결측치를 대체
- **Median substitution(중앙값 대체)**
 - 중앙값으로 결측치를 대체
- **Mode substitution(최빈값 대체)**
 - 가장 높은 빈도의 값으로 결측치를 대체
 - 범주형 데이터에 적용 가능

Retain All Data: Simple Imputation

Mean (Download Speed) = 130



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	N/A	95%
8	Lite	76	77%
9	Fast+	180	95%



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	130	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	130	95%
8	Lite	76	77%
9	Fast+	180	95%

Median (Download Speed) = 155



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	N/A	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	N/A	95%
8	Lite	76	77%
9	Fast+	180	95%



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	157	80%
2	Lite	99	70%
3	Fast+	167	10%
4	Fast+	155	80%
5	Lite	76	70%
6	Fast+	155	10%
7	Fast+	155	95%
8	Lite	76	77%
9	Fast+	180	95%

Mode (Download Speed) = 200



Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	200	80%
2	Lite	100	70%
3	Fast+	200	10%
4	Fast+	N/A	80%
5	Lite	50	70%
6	Fast+	200	10%
7	Fast+	N/A	95%
8	Lite	200	77%
9	Fast+	180	95%





Mobile ID	Mobile Package	Download Speed	Data Limit Usage
1	Fast+	200	80%
2	Lite	100	70%
3	Fast+	200	10%
4	Fast+	200	80%
5	Lite	50	70%
6	Fast+	200	10%
7	Fast+	200	95%
8	Lite	200	77%
9	Fast+	180	95%

Retain All Data: Simple Imputation (for Time-Series)

시계열 데이터의 결측치 대체 방법

- **LOCF** Last Observation Carried Forward
 - 결측치 또는 결측 구간 직전의 값으로 대체
 - pandas 메서드: `ffill()`
- **NOCB** Next Observation Carried Backward
 - 결측치 또는 결측 구간 직후의 값으로 대체
 - pandas 메서드: `bfill()`



LOCF

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	N/A	86%
6	6-Jan	155	87%
7	7-Jan	N/A	89%
8	8-Jan	N/A	90%
9	9-Jan	180	92%



Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	90	86%
6	6-Jan	155	87%
7	7-Jan	155	89%
8	8-Jan	155	90%
9	9-Jan	180	92%

NOCB

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	N/A	86%
6	6-Jan	155	87%
7	7-Jan	N/A	89%
8	8-Jan	N/A	90%
9	9-Jan	180	92%



Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	155	86%
6	6-Jan	155	87%
7	7-Jan	180	89%
8	8-Jan	180	90%
9	9-Jan	180	92%

Retain All Data: Interpolation (for Time-Series)

- 보간법: 결측 구간의 시작/끝 점을 연결하는 **함수를 통해 추정**하는 방법
 - Linear interpolation 선형 보간: 선형 함수 사용



Linear
interpolation

Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	N/A	86%
6	6-Jan	150	87%
7	7-Jan	160	89%
8	8-Jan	N/A	90%
9	9-Jan	180	92%




Mobile ID	Date	Download Speed	Data Limit Usage
1	1-Jan	157	80%
2	2-Jan	99	81%
3	3-Jan	167	83%
4	4-Jan	90	84%
5	5-Jan	120	86%
6	6-Jan	150	87%
7	7-Jan	160	89%
8	8-Jan	170	90%
9	9-Jan	180	92%

$$(90+150)/2 = 120$$

$$(160+180)/2 = 170$$

Retain All Data: Interpolation (for Time-Series)

- **Spline interpolation**(스플라인 보간): 스플라인 함수 사용
 - 예: quadratic spline interpolation(2차 스플라인 함수)
 - 예: cubic spline interpolation(3차 스플라인 함수)



source: Google

Retain All Data: Model-based Imputation



모델 기반 대치 기법

- **Regression**(회귀)
 - 관측된 데이터 기반으로 생성된 회귀 모델을 이용하여 값을 예측
- **k-NN**^{k-Nearest Neighbor}
 - 거리 계산을 통해 가장 가까운 **k** 개의 샘플의 평균/중앙값을 취함
- **EM**^{Expectation-Maximization}
 - 최대우도^{maximum likelihood} 기반 알고리즘을 통해 값을 추정
- **MICE**^{Multiple Imputation by Chained Equations}
 - 반복적으로 대치를 수행하여 얻어진 다수의 데이터셋을 종합(평균, 분산, 신뢰 구간)
- 그 외: 머신러닝/딥러닝 기반 대치 기법

Guideline for Handling Missing Data



- 결측치 비율에 따른 처리 방법
 - 0 ~ 10%: 삭제 or 단순 대체
 - 10 ~ 20%: 핫덱(hot-deck)/회귀/모델 기반 대체
 - 핫덱: 결측이 발생한 샘플과 유사한 샘플들을 대상으로 무작위 표본 추출을 통한 값 대체
 - 20 ~ 50%: 회귀/모델 기반 대체
 - 50% ~: 변수 제거

Guideline for Handling Missing Data



- 결측치 유형에 따른 처리 방법
 - **MCAR** ⇨ Listwise deletion / Pairwise deletion
 - **MAR** ⇨ 모델 기반 대처
 - **MNAR** ⇨ 데이터 조사/개선 필요

8.2 결측 데이터 처리

Indicating the Presence of Missing Data



결측 데이터의 표현

- **마스크^{Mask}**: 전체 결측 데이터를 **부울 배열** 또는 **추가 비트**로 표현
 - 메모리/스토리지 오버헤드 발생
- **센티널 값^{Sentinel Value}**: 개별 결측 데이터를 **특수한 값**으로 표현
 - 일반적으로 특수한 비트 패턴으로 결측을 표현(예: -9999, NaN)

Indicating the Presence of Missing Data

- 언어/시스템에 따라 다른 결측 데이터 표현 방식을 사용
 - R 언어: 센티널 값 방식
 - 예: -1, NA, NaN, "NULL", 0000-00-00
 - SciDB*: 마스크 방식
 - 모든 데이터의 결측 상태를 추가 바이트로 표현
- Pandas는 센티널 값 방식으로 결측 값을 표현
 - None 객체
 - NaN(Not a Number) 값

* 대규모 과학 데이터 관리 및 분석을 위한 오픈소스 DBMS

None: Pythonic Missing Data

- **None 객체**: 아무것도 없는 데이터(= null 값)

- 데이터 타입이 'object'*인 배열에서만 사용

```
arr1 = np.array([1, None, 3, 4])  
arr1.dtype
```

object

```
arr2 = np.array([1, 2, 3, 4])  
arr2.dtype
```

int32

- numpy, pandas 객체에 대한 연산(예: 벡터화된 연산)이 호환되지 않음

```
arr1.sum()
```

TypeError: unsupported operand
type(s) for +: 'int' and
'NoneType'

```
arr2.sum()
```

10

* 컬렉션 객체가 여러 유형의 데이터를 저장하고 있는 경우 데이터 타입(dtype)은 object 이다.

NaN: Missing Numerical Data

- NaN 값: 숫자 형태의 null 값 또는 결측 값을 표현
 - IEEE 754 표준^{*}을 사용하는 모든 시스템들이 인식하는 특수한 부동소수점 Floating Point 값
 - 그 외에도 수학적으로 정의할 수 없는 값(예: $0/0$), 무한대($\infty, -\infty$) 등을 표현할 때 사용

```
arr3 = np.array([1, np.nan, 3, 4])  
arr3.dtype  
  
float64
```

^{*} IEEE에서 개발한 부동소수점 표현 관련 표준

NaN: Missing Numerical Data

- NaN 값에 대한 산술 연산 결과: NaN(적어도 오류는 없음)

```
1 + np.nan
```

```
nan
```

```
0 * np.nan
```

```
nan
```

```
arr3.sum()
```

```
nan
```

- NumPy 에서 제공하는 NaN 값을 무시하는 집계함수

```
np.nansum(arr3)
```

```
8.0
```

```
np.nanmax(arr3)
```

```
4.0
```

```
np.nanmin(arr3)
```

```
1.0
```


NaN and None in Pandas



- Pandas 에서는 None 객체를 자동으로 NaN 값으로 변환

```
pd.Series([1, np.nan, 2, None])
```

```
0    1.0  
1    NaN  
2    2.0  
3    NaN  
dtype: float64
```

Operating on Null Values



- 결측치 처리를 위한 Pandas 메서드
 - `isnull()`: 전체 결측 데이터에 대한 부울 배열(마스크) 생성
 - `notnull()`: `isnull()`의 역연산
 - `dropna()`: null 값 제거
 - `fillna()`: null 값 채우기

Detecting Null Values



- `isnull()`, `notnull()`: 마스크를 통해 Null 값을 표현

```
ser = pd.Series([1, np.nan, 'hello', None])
ser.isnull()

0    False
1     True
2    False
3     True
dtype: bool
```

```
ser.notnull()

0     True
1    False
2     True
3    False
dtype: bool
```

Dropping Null Values

- `dropna()`: NaN값을 포함하는 행 또는 열을 삭제
 - `axis=0`: 행 삭제(= listwise deletion, default 옵션)
 - `axis=1`: 열 삭제(= variable deletion)

DataFrame

	A	B	C
0	A0	NaN	C0
1	A1	B1	C1
2	NaN	B2	C2

행 삭제

```
df.dropna()
```

[Out]:

	A	B	C
1	A1	B1	C1

열 삭제

```
df.dropna(axis=1)
```

[Out]:

	C
0	C0
1	C1
2	C2

Dropping Null Values

- `how` 매개변수
 - `how='any'` : NaN 값이 한개라도 포함된 행 또는 열 삭제
 - `how='all'` : 모든 값이 전부 NaN 값인 행 또는 열 삭제

	A	B	C
0	A0	NaN	NaN
1	A1	B1	NaN
2	NaN	B2	NaN

```
df.dropna(axis=0, how='any')
```

[Out]:

A	B	C

```
df.dropna(axis=1, how='all')
```

[Out]:

	A	B
0	A0	NaN
1	A1	B1
2	NaN	B2

Dropping Null Values

- `thresh` 매개변수: Non-null 값의 개수가 임계치 보다 작은 행 또는 열을 삭제

	A	B	C
0	A0	NaN	NaN
1	A1	B1	NaN
2	NaN	B2	NaN

```
df.dropna(axis=0, thresh=2)
```

[Out]:

	A	B	C
1	A1	B1	NaN

```
df.dropna(axis=1, thresh=2)
```

[Out]:

	A	B
0	A0	NaN
1	A1	B1
2	NaN	B2

Filling Null Values



- `fillna()`: NaN 값을 다른 값으로 대체

```
ser = pd.Series([1, np.nan, 2, None, 3],  
                index=list('abcde'))
```

```
a      1.0  
b      NaN  
c      2.0  
d      NaN  
e      3.0  
dtype: float64
```

```
ser.fillna(0)
```

```
a      1.0  
b      0.0  
c      2.0  
d      0.0  
e      3.0  
dtype: float64
```

Filling Null Values



- **Forward-fill** 방식 = LOCF
 - 결측 구간 직전에 측정된 값으로 대체

Series 객체

```
a    1.0
b    NaN
c    2.0
d    NaN
e    3.0
dtype: float64
```

```
ser.fillna(method='ffill')
```

```
a    1.0
b    1.0
c    2.0
d    2.0
e    3.0
dtype: float64
```

또는
`ser.fffll()`

Filling Null Values

- **Backward-fill** 방식 = NOCB
 - 결측 구간 직후에 측정된 값으로 대체

Series 객체

```
a    1.0
b    NaN
c    2.0
d    NaN
e    3.0
dtype: float64
```

```
ser.fillna(method='bfill')
```


[Out]:

```
a    1.0
b    2.0
c    2.0
d    3.0
e    3.0
dtype: float64
```

또는
`ser.bfill()`

Imputation Demo

- 예제: Air Quality 데이터셋에 대한 결측치 처리



References



- Premanand, S. *A Complete Guide to Dealing with Missing values in Python*, Analytics Vidhya ([link](#))
- Roy, B. *All About Missing Data Handling*, towards data science ([link](#))
- van Buuren, S., *Flexible Imputation of Missing Data (Online)* ([link](#))
- Lee, B, et al., *Improving Load Forecasting of Electric Vehicle Charging Stations Through Missing Data Imputation*, *Energies*, 2020 ([link](#))
- VanderPlas, J., *Python Data Science Handbook*, GitHub ([link](#))
- 나아무늘보, *[ML/DL] 결측치의 종류와 결측치 처리 가이드라인*, 티스토리 ([link](#))
- Lee, H., *[데이터분석이론] #1 Missing Data Mechanism*, GitHub ([link](#))
- 데이터 품질진단 절차 및 기법, 한국데이터베이스진흥원
- 만년필링크, *결측값: 1.1 기본개념(2) - 결측값의 종류*, 티스토리 ([link](#))
- 김정인, *파이썬 데이터 사이언스 핸드북*, 위키북스, 2017.



수고하셨습니다.